

UNIVERSIDADE FEDERAL DE ALAGOAS

CAMPUS A.C. SIMÕES

ENGENHARIA DE COMPUTAÇÃO

DAVI CELESTINO DOS SANTOS BARBOSA, 23210541

JOÃO VICTOR TENÓRIO VENANCIO, 23211191

OTAVIO JOSHUA COSTA BRANDAO MENEZES, 23211189

LARISSA FERREIRA DIAS DE SOUZA, 23211102

**RELATÓRIO TÉCNICO: SISTEMA INTELIGENTE DE PERGUNTAS E
RESPOSTAS (AKINATOR DE ANIMAIS)**

MACEIÓ - AL

2025

UNIVERSIDADE FEDERAL DE ALAGOAS

CAMPUS A.C. SIMÕES

ENGENHARIA DE COMPUTAÇÃO

DAVI CELESTINO DOS SANTOS BARBOSA, 23210541

JOÃO VICTOR TENÓRIO VENANCIO, 23211191

OTAVIO JOSHUA COSTA BRANDAO MENEZES, 23211189

LARISSA FERREIRA DIAS DE SOUZA, 23211102

**RELATÓRIO TÉCNICO: SISTEMA INTELIGENTE DE PERGUNTAS E
RESPOSTAS (AKINATOR DE ANIMAIS)**

Este relatório descreve a modelagem, a arquitetura e a análise de resultados de um sistema de inteligência artificial baseado em conhecimento, inspirado no jogo Akinator. O sistema utiliza técnicas de Teoria da Informação para identificar entidades dentro de um domínio específico através de um processo iterativo de eliminação de hipóteses.

Orientador (a): Prof. Dr. Evandro de Barros Costa

MACEIÓ - AL

2025

1. DESCRIÇÃO DO DOMÍNIO

O domínio escolhido para este sistema foi o de Animais. O escopo foi delimitado para garantir diversidade taxonômica e fenotípica, testando a capacidade de discriminação do motor de inferência.

- Entidades: A base de dados conta com 25 animais distintos, variando entre animais domésticos (Cachorro, Gato), selvagens de grande porte (Leão, Elefante), animais marinhos (Baleia, Tubarão, Polvos) e até mesmo espécies extintas (T-Rex).
- Atributos: Foram mapeadas 21 características (perguntas) booleanas para descrever as entidades. Estes atributos cobrem classificações biológicas (mamífero, ave, réptil), habitat (aquático, África), dieta (carnívoro, herbívoro) e características físicas marcantes (penas, pelo, venenoso, pescoço longo).

2. ESTRATÉGIA DE REPRESENTAÇÃO DO CONHECIMENTO

O conhecimento do domínio foi modelado de forma explícita e declarativa através de matrizes associativas (dicionários em Python). A relação entre os animais e suas características não é estritamente binária, incorporando uma representação tolerante à incerteza.

Cada entidade é mapeada para os atributos através de uma lógica de três estados:

- 1 (Verdadeiro): O animal possui inequivocamente a característica.
- 0 (Falso): O animal não possui a característica.
- -1 (Neutro/Inaplicável): Representa incerteza inerente ou um atributo que não se aplica claramente à entidade (reduzindo eliminações acidentais).

Essa estrutura garante que a adição de novos animais ou perguntas no futuro seja feita apenas atualizando o arquivo de dados (`knowledge_base.py`), sem necessidade de recompilar as regras do motor lógico.

3. MECANISMO DE INFERÊNCIA UTILIZADO

A abordagem adotada combina Busca em Espaço de Hipóteses com Poda Lógica e heurísticas da Teoria da Informação (Entropia). O sistema não utiliza uma árvore de decisão estática; a próxima pergunta é calculada em tempo real com base no estado atual do jogo.

Algoritmo de Ganho de Informação (Information Gain)

Para minimizar o número de perguntas necessárias, o motor (InferenceEngine) calcula qual atributo divide o conjunto restante de hipóteses o mais próximo possível de 50/50. Para isso, utiliza-se o conceito de Entropia de Shannon (H):

$$H(S) = - \sum p_i \log_2(p_i)$$

A cada turno, o sistema avalia o Ganho de Informação (IG) de cada atributo ainda não perguntado:

$$IG(attr) = H(S) - H(S|attr)$$

Onde S é o conjunto atual de animais possíveis. O atributo com o maior IG é selecionado para ser perguntado ao usuário.

Eliminação de Hipóteses

Com a resposta do usuário, o espaço de busca é atualizado:

- Sim (s): Elimina todas as hipóteses cujo atributo seja 0.
- Não (n): Elimina todas as hipóteses cujo atributo seja 1.
- Não Sei (ns): Absorve a incerteza humana. Nenhuma hipótese é eliminada, mas o atributo é marcado como "perguntado" para não entrar em loop. Hipóteses cadastradas com valor -1 sobrevivem a respostas "Sim" e "Não".

4. EXEMPLOS DE INTERAÇÃO

Abaixo, um fluxo típico de inferência, demonstrando a convergência rápida do algoritmo (Exemplo: Usuário pensa no Pinguim):

1. Início: 25 hipóteses restantes.
2. Pergunta 1 (Maior Ganho de Informação): "É um mamífero?"
 - Resposta do usuário: n (Não).
 - Ação: Mamíferos como Leão, Cachorro e Baleia são eliminados. Restam 11 hipóteses.
3. Pergunta 2: "É uma ave?"
 - Resposta do usuário: s (Sim).
 - Ação: Répteis e insetos são eliminados. Restam 4 hipóteses (Águia, Pinguim, Papagaio, Flamingo).
4. Pergunta 3: "Vive na água (total ou parcialmente)?"
 - Resposta do usuário: s (Sim).
 - Ação: Águia e Papagaio são eliminados. Restam 2 hipóteses (Pinguim, Flamingo).
5. Pergunta 4: "Tem pescoço visivelmente longo?"
 - Resposta do usuário: n (Não).
 - Ação: Flamingo eliminado.
6. Conclusão: O sistema deduz a resposta correta: Pinguim (em apenas 4 perguntas).

5. ANÁLISE DOS RESULTADOS OBTIDOS

Para avaliar a robustez e eficiência da arquitetura, foram realizados testes simulados automatizados (via script `test_metrics.py`) iterando sobre todo o conjunto de dados em dois cenários distintos.

Cenário 1: Respostas Ideais (0% de incerteza)

Neste cenário, simulou-se um usuário que possui conhecimento absoluto sobre as entidades, respondendo apenas "Sim" ou "Não".

- Taxa de Acerto: 100% (25/25 animais identificados corretamente).
- Média de Perguntas: approx 4.8 perguntas por animal.
- Análise: O desempenho aproxima-se do limite teórico ótimo para buscas binárias. Como $2^4 = 16$ e $2^5 = 32$, a média de 4.8 valida a excelência matemática da heurística de entropia aplicada a 25 elementos.

Cenário 2: Condições Realistas e Incerteza (20% de "Não Sei")

Para testar a resiliência do motor contra ambiguidades ou falhas de conhecimento do usuário final, injetou-se uma probabilidade de 20% de o usuário responder "Não Sei" a qualquer característica.

- Taxa de Acerto: Manteve-se altíssima (frequentemente >95% dependendo da semente aleatória), demonstrando que o sistema compensa a falta de informação buscando vias alternativas no grafo.
- Média de Perguntas: Aumentou para a faixa de 6.5 a 7.0 perguntas.
- Casos de Falha: Falhas ocorreram apenas quando atributos vitais de separação foram respondidos com "Não Sei" em demasia, resultando no esgotamento das 21 perguntas disponíveis e forçando o sistema a chutar a hipótese de maior probabilidade restante na lista (empate técnico).

Conclusão dos Experimentos:

O uso do Ganho de Informação mitigou o risco de árvores de decisão desbalanceadas, confirmando que a abordagem dinâmica é amplamente superior a fluxogramas estáticos para domínios de conhecimento complexos.